


1. Segmentación de clientes



- 1. **Diagrama de Caja (Boxplot - Arriba):**
 - Apretada a la izquierda representa el rango intercuartílico (donde se concentra el 50% central de los clientes, entre los percentiles 25 y 75).
 - Todos los puntos negros que se extienden infinitamente hacia la derecha son los outliers (valores atípicos).
 - También puedes notar hacia la izquierda del cero que existen algunos valores atípicos negativos (clientes con saldo negativo de hasta -2,258).
- 2. **Histograma (Abajo):**
 - Muestra que la inmensa mayoría de los clientes se aglomera en una gran columna vertical muy cerca del 0 y hasta los 1,000.
 - Debido a los valores extremos (la "cola larga" a la derecha), si hubiéramos intentado dividir a los clientes con rangos fijos tradicionales

Segmento	Cantidad de Clientes	% del Total	ARPU Promedio	Tasa de Churn
Bajo	49,850	25.00%	40.68	2.77%
Medio	99,698	50.00%	205.99	0.83%
Alto	39,879	20.00%	532.81	0.68%
Premium	9,970	5.00%	1,237.58	0.63%

INSIGHTS

1. **Correlación directa con la fuga:** Existe una clara **relación inversa entre el valor del cliente (ARPU) y su probabilidad de abandono**. Los clientes del segmento *Bajo* tienen una tasa de fuga (2.77%) que es más de **4 veces superior** a la de los clientes *Premium* (0.63%).
2. **Concentración de riesgo:** Aunque los clientes **Premium y Altos son más leales, cualquier esfuerzo de retención debe priorizarse altamente en ellos**, pues su "ARPU Promedio" demuestra que perder un solo cliente Premium duele financieramente igual que perder a casi varios bajos

3. Generación de variables


`monto_promedio_recarga`

- **Cálculo:** Monto total mensual dividido entre la cantidad de recargas (asignando 0 si no hubo transacciones).
- **Valor predictivo:** Permite distinguir entre clientes con solvencia y planeación (pocas recargas de alto valor) y aquellos que recargan por urgencia (múltiples recargas de bajo valor).

`vol_total_datos_mb`

- **Cálculo:** Suma de los megabytes consumidos en las redes 2G y 3G.
- **Valor predictivo:** Evalúa el "enganche digital" general del cliente. Consumo sin la fricción de redes fragmentadas.

4. Análisis de churn



1. Comportamiento del Churn en el tiempo (Patrones Relevantes)

El problema de fuga de clientes se está agravando mes a mes. En agosto, **la empresa perdió a casi el doble de clientes de los que perdió en junio**. Esto valida que predecir el churn es un "problema crítico" y urgente para el negocio.

2. Comparación: Clientes que hacen Churn vs. Los que se quedan

El comportamiento es que primero deja de usar datos de internet, luego reduce drásticamente las llamadas que hace y recibe, y consecuentemente sus recargas caen a menos de la mitad del promedio habitual.

4. Limpieza de datos (decisión abierta)

1. Eliminación de Columnas

- **Identificadores (`mobile_number`):** Se descartan porque no tienen poder predictivo y solo introducen ruido al modelo.
- **Fechas crudas:** Los algoritmos no procesan texto de fechas.
- **Variables redundantes (Colinealidad):** Se eliminan los subtotaes específicos que ya están consolidados en columnas totales

2. Tratamiento de Valores Nulos

- **Consumo de Datos/Internet (75% nulos):** Se imputan con **0**. En el negocio de telecomunicaciones, un nulo aquí significa que el cliente prepago no compró un paquete. Usar promedios introduciría datos falsos.
- **Minutos de Voz/MOU (4% nulos):** Se imputan con **0**, siguiendo la misma lógica comercial: el cliente simplemente no usó la red para llamadas en ese periodo.

3. Variables adicionales

- **ARPU negativo:** Valores extremos generan ruido estadístico y requieren validación para saber si son ajustes de facturación o errores del sistema.
- **Outliers masivos:** Registros de ingresos astronómicos (>35,000 vs. promedio de 281) que podrían indicar fraude, errores tipográficos o clientes corporativos mezclados en la base.
- **Registros fantasma:** Filas sin la fecha de cierre de mes (`last_date_of_month` nulo), lo que imposibilita ubicarlas en el tiempo.

4. Riesgos del Enfoque

- **Fallas técnicas ocultas:** Al asumir que un nulo es "Cero consumos", corres el riesgo de sesgar el modelo si ese nulo fue en realidad un fallo del servidor de la antena que no registró el tráfico.
- **Outlier:** Limpiarlos borra del mapa a los clientes *Premium*; dejarlos arruina los modelos sensibles a la escala (como Regresión Logística).
- **Desbalanceo:** Como el *churn* es solo del 1.2%, un modelo sin ajustar predecirá que nadie se fuga. Es obligatorio aplicar técnicas de balanceo (SMOTE o penalizaciones) antes de entrenar.

5. Otros análisis (opcional)

- **El Comportamiento:** En telecomunicaciones, existe un patrón el mes previo a la fuga donde el cliente comienza a desconectarse.
- **El Hallazgo:** A diferencia de los clientes leales que mantienen un consumo estable, los que abandonan muestran un colapso abrupto.
- **La Solución:** Crear **Variables de Variación**, este hundimiento numérico es un predictor de fuga mucho más fuerte y evidente que el valor absoluto del mes de forma aislada.

2. Recencia: Días sin Recarga

- **El Insight:** Aunque la fecha cruda de la última recarga debe eliminarse por su formato incomprensible para el algoritmo.
- **La Solución:** Construir una nueva variable que mida los "**Días transcurridos desde la última recarga**", clientes prepago pasar muchos días sin saldo es una señal crítica de que probablemente ya desearon la tarjeta SIM y cambiaron de operador.

6. Modelamiento

1. Enfoque del Modelo: Random Forest (Balanceado)

- **Inmunidad a outliers:** Al basarse en "cortes" y no en distancias matemáticas, ignora las distorsiones de los valores extremos (ej. ARPU astronómicos).
- **Cálculo de probabilidades:** Promedia árboles para entregar un riesgo continuo (ej. 98.5%), lo que permite rankear a los clientes y extraer exactamente el "Top 2000".
- **Captura de no-linealidad:** Detecta de forma natural los cambios abruptos en el comportamiento que anteceden a la fuga.

2. Evaluación Financiera (Simulación en Top 2000)

- **Rendimiento:** 619 *churners* reales detectados (31% de precisión en el Top 2000).
- **Retención:** 62 clientes salvados (tasa de éxito del 10%).

3. Conclusión y Próximo Paso (Iteración con Deltas)

- **Diagnóstico:** Estadísticamente, el modelo separa las clases muy bien (**ROC-AUC 0.87**) y es infinitamente superior al azar, pero **quedó corto por apenas 48 aciertos** para alcanzar el punto de equilibrio financiero (667 *churners*).
- **Solución para lograr rentabilidad:** La iteración actual se entrenó con datos "crudos". Para superar el umbral y generar ganancias, la siguiente versión se entrenará con **Variables de Variación** esto hará al algoritmo hiper-sensible al "Efecto Caída" del último mes, afinando drásticamente su precisión en el Top 2000.

7. Priorización de clientes

1. Estrategia de Selección: Scoring y Top K

Enfoque de **Propensity Scoring**:

- **Scoring:** El modelo asignará a cada cliente una probabilidad exacta de fuga (del 0% al 100%).
- **Ranking:** Toda la base activa se ordenará de forma descendente, desde el mayor al menor riesgo.
- **Selección (Top K):** Se hará un corte estricto en la fila **2,000** para definir el público objetivo del Call Center.

2. Justificación Matemática:

Aunque habitualmente se ordena por "Valor en Riesgo", Las reglas dictan valores fijos (recuperación de \$30,000 CLP y éxito del 10%). Al ser constantes, el valor esperado depende de una sola variable: **la probabilidad de fuga**.

- **Fórmula de Ganancia Esperada:** $(\text{Probabilidad} \times 10\% \times \$30,000 \text{ CLP}) - \$1,000 \text{ CLP de costo}$.
- **Conclusión:** En este escenario, ordenar la lista por probabilidad de *churn* es matemáticamente exacto a ordenarla por rentabilidad.

3. Justificación de Negocio:

Esta metodología ataca directamente la única métrica que importa para este problema: la **Precisión en los primeros 2,000 registros**.

- **Elimina la dilución de aciertos:** Ignora el umbral estándar del 50%, el cual sugeriría llamar a demasiados clientes. Elegir 2,000 al azar dentro de ese grupo bajaría la tasa de éxito y generaría pérdidas.
- **Garantiza el punto de equilibrio:** Al atacar únicamente la "punta de la pirámide" (probabilidades más cercanas al 100%), se minimizan las falsas alarmas que queman el presupuesto y se asegura cruzar la barrera de los **667 verdaderos churners** necesarios para que la campaña de \$2,000,000 CLP no pierda dinero.

8. Mejora del modelo

1. Mejoras de Rendimiento (Superar el ROI)

Para cruzar la meta de los 667 aciertos y generar ganancias netas, el enfoque técnico debe evolucionar:

- **Migración de Algoritmo:** Pasar de Random Forest a modelos de *Gradient Boosting* (XGBoost o LightGBM), superiores en datos tabulares y en el manejo matemático del desbalanceo.
- **Tuning orientado al negocio:** Ajustar los hiperparámetros utilizando una métrica personalizada que optimice exclusivamente la **Precisión en el Top 2000**, ignorando el *Accuracy* global.

2. Información adicional

Los datos transaccionales muestran el síntoma, pero predecir con base en las causas raíz dispararía la eficacia del modelo. Sería ideal incorporar:

- **Atención al Cliente:** Historial de quejas o tickets técnicos abiertos (el mayor detonante de fuga).
- **Calidad de Red:** Métricas técnicas como la tasa de llamadas caídas o latencia por antena.
- **Dispositivo y Demografía:** Tipo de celular (ej. smartphone 4G), antigüedad del cliente en la compañía y rango de edad.
- **Portabilidad:** Consultas recientes del PIN de portabilidad numérica (intención explícita de abandono).

3. Simplificación para Despliegue en Producción

Para lanzar el modelo a producción a corto plazo de forma ágil, robusta y sin sobrecargar la ingeniería de datos:

- **Selección de Variables (Feature Selection):** Reducir el modelo de 56 variables estrictamente al Top 10-15 más predictivo para aligerar la carga de los servidores.
- **Ejecución Batch (Por Lotes):** Evitar infraestructuras complejas en tiempo real. Ejecutar el modelo una vez al mes durante la madrugada para depositar el "Top 2000" directamente en el CRM del Call Center.